Metrología y transferencia del campo `confidence` en modelos de decisión de pesos abiertos tipo Jev

Arbués Enrique Pérez Villegas
Facultad de Ciencias
Universidad Nacional de Ingeniería (FC-UNI)
Lima, Perú
arbues.perez.v@uni.pe
ORCID: 0009-0004-7605-6569

***Resumen*—Los modelos de decisión tipo Jev no generan texto: terminan la inferencia con un *readout* de logits y exponen un campo `confidence` sobre el que el ecosistema fija umbrales de actuación. Sin embargo, el mismo nombre cubre definiciones matemáticamente incompatibles. Este trabajo construye y publica un *instrumento* para medirlo: la especificación formal de las definiciones en uso, la librería `jev-conf-metrics`, un conjunto de 65 185 decisiones medidas sobre pesos abiertos y una matriz de transferencia de umbrales que se regenera con un solo comando. Sobre 3 564 celdas y 23 grupos (Laya en tres *checkpoints*, Kev-0.8B y un control crudo), la diferencia entre la definición más alta y la más baja de la *misma* distribución tiene mediana 0.288; el porte directo de un umbral se equivoca del orden de cien veces más que el porte con el mapa cerrado cuando este existe; solo dos pares de definiciones transfieren por identidad matemática; y la incompatibilidad es un fenómeno de $n \geq 3$. El mismo modelo ofrece un ECE de 0.216 o de 0.577 según la definición. La contribución es el instrumento de medición, que se aplica a cualquier implementación futura del campo sin volver a medir el corpus.**

***Index Terms*—calibración, modelos de decisión, Jev, transferencia de umbrales, predicción selectiva, pesos abiertos.**

I. Introducción

Los modelos de lenguaje grandes responden generando texto: la secuencia de tokens *es* la respuesta y su longitud es el costo. En septiembre de 2026 apareció una familia distinta. Los modelos de decisión (o modelos *System One*) reciben una pregunta y un conjunto cerrado y etiquetado de opciones, y responden con una opción y una probabilidad, sin emitir texto: terminan la inferencia con un *readout* de logits en la posición de cada etiqueta permitida [1], [2]. Su costo de salida es nulo —el proveedor no cobra los tokens de salida—, su latencia es de decenas de milisegundos, y se ofrecen como el componente que decide «qué hacer» dentro de un sistema mayor: clasificar, enrutar, verificar, abstenerse.

Jev, de TypeSafe, abrió la categoría el 18 de septiembre de 2026 [1]. En menos de un mes floreció un ecosistema open-source de pesos abiertos que replica su contrato: Laya (421M, la única implementación que publica el bucle de entrenamiento RLCD completo) [3], Kev como familia entrenable [4], y una decena de derivados (Nimble, SemIf, Jeff, jev-lite, AnyJev, entre otros) [5]–[9]. Todos exponen el mismo campo: `confidence`.

Ese campo es el que hace útil al modelo. Un despliegue típico no usa la etiqueta a secas: fija un umbral sobre `confidence` y decide *actuar*, o *escalar a un humano* cuando el modelo no está seguro [10], [11]. El umbral, por tanto, es la política. Y aquí está el problema: aunque el campo se llame igual en todo el ecosistema, su definición no es la misma (Tabla I).

Tabla I
Definiciones de `confidence` presentes en el ecosistema.

implementación	definición de `confidence`	fórmula
Jev	concentración	$(n\,p_{\max}-1)/(n-1)$ [2]
Laya (`choice`, `score`)	entropía normalizada	$1-H(p)/\log n$ [12]
Laya (`noul`)	probabilidad binaria	$\max(p, 1-p)$ [12]
jev-lite, Laya `answer_confidence`	probabilidad ganadora	$p_{\max}$ [8]
otros derivados	margen, prior aprendido	$p_{(1)}-p_{(2)}, \ldots$

El efecto es inmediato: una sola distribución sobre tres opciones, $(0{,}0118, 0{,}4629, 0{,}5253)$, produce tres valores distintos de `confidence`: 0.288 con la fórmula de Jev, 0.3199 con la entropía de Laya y 0.5253 con $p_{\max}$ [13]. Es el mismo dato y el número cambia según quién lo calcule. Un umbral calibrado sobre una definición, portado a otra, no significa lo mismo, y el ecosistema los porta entre modelos como si fueran intercambiables.

La afirmación cualitativa «los umbrales no transfieren» ya circula en anécdotas [14]. Lo que no existe es la medición sistemática: cuánto se degrada la cobertura y la precisión del umbral al portarlo entre definiciones, modelos y datasets. Esa tabla es la que este trabajo construye, y la construye con un instrumento que se regenera con un comando.

Contribuciones.

1. Una especificación formal de cada definición de `confidence` en uso, como función de la distribución devuelta y de la cardinalidad n (dominio, rango, monotonía), con tres proposiciones que separan las definiciones que son *equivalentes en orden* (transferencia exacta de umbral) de las que no lo son, y que muestran que la incompatibilidad aparece solo a partir de $n = 3$.
2. La librería `jev-conf-metrics`, que implementa todas las definiciones y las métricas de calibración y discriminación, con 67 tests de conformidad contra salidas publicadas.
3. La matriz de transferencia de umbrales (definición origen $\times$ definición destino $\times$ modelo $\times$ dataset), el dataset de 65 185 mediciones crudas con versión y hash por fila,

las figuras y los scripts regeneradores que la reproducen sin GPU.

4. El pre-registro de la cobertura objetivo, las definiciones y los datasets antes de la corrida principal (DOI `10.5281/zenodo.23266795`).

Con ese instrumento, el trabajo mide y responde: sobre 65 185 decisiones medidas con cinco configuraciones de modelo, la definición más alta y la más baja de la misma distribución difieren con mediana 0.288; y portar el umbral sin traducirlo se equivoca del orden de cien veces más que portarlo con el mapa matemático cuando este existe.

El trabajo no reporta un hallazgo sobre si la calibración «viaja» o no: entrega el instrumento con el que se mide. Es el patrón de [15], que no descubrió que las redes modernas están des-calibradas, sino que dio la métrica y la corrección que el campo entero cita. Toda afirmación posterior sobre la transferencia de umbrales puede contrastarse contra esta matriz, que se regenera con un comando y declara el hash de cada fila medida.

Organización. La Sección 2 sitúa el trabajo frente a la calibración, las reglas de puntuación propias, la predicción selectiva y el ecosistema Jev-OSS. La Sección 3 fija el marco teórico: definiciones, calibración frente a discriminación, las proposiciones de equivalencia en orden y la definición formal de la transferencia de umbrales. Las Secciones 4 a 7 describen el método, los resultados, la discusión y las conclusiones, y listan los artefactos entregados.

II. Trabajos relacionados

Este trabajo se sitúa en la intersección de cuatro cuerpos de literatura (calibración, reglas de puntuación propias, predicción selectiva y calibración post-hoc) y de un quinto, reciente y aún en formación: el ecosistema de modelos de decisión tipo Jev.

Calibración de clasificadores. Un predictor probabilístico está calibrado si, de las veces que anuncia confianza c, acierta con frecuencia c. [16] mostró que los clasificadores clásicos están sistemáticamente mal calibrados. [15] lo reabrió para las redes profundas modernas y popularizó el Expected Calibration Error (ECE) con su temperature scaling. El ECE, formalizado por [17], depende críticamente del esquema de partición (bins de igual ancho frente a bins de igual masa), un detalle que el ecosistema Jev-OSS omite al reportar. La discriminación (capacidad de ordenar aciertos por confianza, medida con AUROC) es una propiedad distinta de la calibración; ambas se reportan aquí.

Reglas de puntuación propias. [18] caracterizan las reglas estrictamente propias, cuyo óptimo se alcanza declarando la distribución verdadera. Es la base teórica de RLCD: la recompensa de Jev combina la regla logarítmica con la esférica, y el RPS para salidas ordinales [19]–[21]; la esférica tiene caracterización axiomática propia [22]. La teoría predice que reportar honestamente es la única estrategia óptima; la práctica del ecosistema la contradice, como se ve en el cierre de esta sección.

Predicción selectiva. [10] derivó la política óptima de rechazo: actuar cuando $p > 1 - C_{\text{esc}}/C_{\text{err}}$. [11] llevaron la idea a redes profundas y a las curvas *risk–coverage* y el AURC; [23] estudian cuándo basta la confianza para derivar. Todos estos umbrales suponen que la confianza está calibrada, que es exactamente lo que este trabajo pone a prueba cuando la confianza tiene varias definiciones.

Calibración post-hoc y conformal. [24] y [25] dan la escala de Platt y la regresión isotónica; [15] la temperatura. [26], [27] ofrecen, con la predicción conformal, cobertura con garantía libre de distribución, como alternativa a calibrar `confidence`.

El ecosistema Jev-OSS (2026). [1], [2] describen el modelo y sus primitivos; [28], [29] reconstruyen su arquitectura y la mecánica de RLCD a partir de sondeos de la API. [3] publica la primera implementación abierta con pesos y receta; [4]–[7] le siguen. Los cierres de septiembre de 2026 (por qué RLCD no calibra [30], [31], la coherencia de la negación [32], el sesgo nombre–definición [33] y la cartografía del ecosistema [34]) ocupan el «por qué» y el «qué hay». La reproducción pre-registrada de [35] es el estado del arte más cercano: mide la calibración de Laya dentro de una sola definición ($q = p_{\text{máx}}$) y encuentra que el umbral no transfiere entre datasets. Lo que ninguno hace es comparar entre definiciones.

El hueco. La literatura mide la calibración de un modelo bajo una definición, o comprueba cualitativamente que un umbral no viaja. No existe la matriz que cuantifica, par a par y definición a definición, cuánta cobertura y precisión se pierden al portar un umbral. Esa es la contribución de este trabajo.

III. Marco teórico

III-A. Notación

Sea una pregunta con n opciones etiquetadas (n es la cardinalidad; el primitivo `choice` admite hasta 255 y `score` entre 2 y 10). El modelo devuelve una distribución $p = (p_1, \ldots, p_n)$ sobre las opciones, con $p_i \geq 0$ y $\sum_i p_i = 1$, y la etiqueta correcta es $y \in \{1, \ldots, n\}$. Escribimos $p_{\text{máx}} = \text{máx}_i\, p_i$, $\hat{y} = \arg\text{máx}_i\, p_i$, y el acierto $a = \mathbf{1}[\hat{y} = y]$. Con $H(p) = -\sum_i p_i \log p_i$ denotamos la entropía de Shannon (el logaritmo es indistinto mientras se normalice). Ordenamos las probabilidades de mayor a menor: $p_{(1)} \geq p_{(2)} \geq \cdots \geq p_{(n)}$, de modo que $p_{(1)} = p_{\text{máx}}$.

III-B. El campo `confidence` como función de la distribución

Cada implementación define `confidence` como una función distinta de p y de n (Tabla II):

Para una misma p, estas funciones toman valores distintos. Esta es la fuente de la incompatibilidad de umbrales: el umbral es un punto en el rango de una función, y los rangos no coinciden (Tabla III).

Tabla II
Definiciones de `confidence` como función de la distribución p y de la cardinalidad n.

definición	fórmula	dominio	quién la usa
concentración de Jev	$C_{\text{Jev}}(p) = (n\,p_{\text{máx}} - 1)/(n-1)$	$[0,1]$	Jev, Kev
entropía normalizada	$C_{\text{ent}}(p) = 1 - H(p)/\log n$	$[0,1]$	Laya (`choice`, `score`)
probabilidad ganadora	$C_{\text{máx}}(p) = p_{\text{máx}}$	$[1/n, 1]$	jev-lite, `answer_confidence`
margen	$C_{\text{mar}}(p) = p_{(1)} - p_{(2)}$	$[0,1]$	derivados
`noul` (binario)	$C_{\text{noul}}(p) = \text{máx}(p, 1-p)$	$[1/2, 1]$	Laya (`noul`)

Tabla III
LA MISMA DISTRIBUCIÓN, CUATRO DEFINICIONES, CUATRO NÚMEROS.

p $(n=3)$	C_{Jev}	C_{ent}	$C_{\text{máx}}$	C_{mar}
$(0{,}0118, 0{,}4629, 0{,}5253)$	0.288	0.320	0.525	0.062

III-C. Calibración frente a discriminación

La calibración pregunta si el número es *creíble*: $P(\hat{y} = y \mid C = c) = c$ para todo c. La discriminación pregunta si el número *ordena bien*: si los aciertos reciben valores de C más altos que los errores, y se mide con $\text{AUROC}(C, a)$. Un modelo puede discriminar bien y estar des-calibrado, y dos definiciones pueden discriminar idéntico y calibrar distinto: por eso el trabajo reporta ambas. El ECE (Error de Calibración Esperado) con M bins B_m es

$$\text{ECE} = \sum_m \frac{|B_m|}{N} \cdot |\text{acc}(B_m) - \text{conf}(B_m)|,$$

y se calcula en dos esquemas, bins de igual ancho y de igual masa, porque el número cambia entre ellos [15], [17]. Como métricas de error probabilístico se usan la Brier multiclase $\text{Brier} = (1/N)\sum_i \sum_k (p_{ik} - y_{ik})^2$ [36] y la NLL $-(1/N)\sum_i \log p_i(y_i)$.

III-D. Equivalencia en orden y transferencia exacta

El punto teórico del trabajo es que la incompatibilidad no es uniforme: algunas definiciones están relacionadas por una transformación monótona, y entonces el umbral transfiere exacto; otras no lo están. Lo fijamos en tres proposiciones (demostraciones y comprobación numérica en `paper/03_especificacion_confidence.md`).

Proposición 1 (equivalencia en orden). Sea n fijo. La definición de Jev es afín y estrictamente creciente en $p_{\text{máx}}$: $C_{\text{Jev}} = \alpha\, p_{\text{máx}} + \beta$ con $\alpha = n/(n-1) > 0$ y $\beta = -1/(n-1)$. En consecuencia, C_{Jev} y $C_{\text{máx}}$ son **equivalentes en orden**: existe ϕ estrictamente creciente con $C_{\text{Jev}} = \phi(C_{\text{máx}})$. Un umbral τ sobre C_{Jev} induce el mismo conjunto de actuaciones y abstenciones que el umbral $\phi^{-1}(\tau)$ sobre $C_{\text{máx}}$, y la cobertura es idéntica.

Proposición 2 (no equivalencia con la entropía). Para $n \geq 3$ existen distribuciones p, p' con $p_{\text{máx}} = p'_{\text{máx}}$ y $H(p) \neq H(p')$. Por tanto C_{ent} **no** es función de $p_{\text{máx}}$ solo, y en general **no** existe ϕ monótona con $C_{\text{ent}} = \phi(C_{\text{máx}})$. El umbral no transfiere entre una definición tipo $p_{\text{máx}}$ y una tipo entropía.

Proposición 3 (degeneración en $n = 2$). Con $n = 2$, $C_{\text{Jev}} = 2\, p_{\text{máx}} - 1 = C_{\text{mar}}$, esto es, la definición de Jev y el margen son la **misma** función; y C_{ent}, con H función de un solo parámetro, es también una transformación estrictamente monótona de $p_{\text{máx}}$. Por tanto en $n = 2$ **todas** las definiciones son equivalentes en orden, y la incompatibilidad de umbrales es un fenómeno exclusivo de $n \geq 3$ con distribuciones dispersas.

Consecuencia: el fallo tiene dos capas. Si dos definiciones son equivalentes en orden pero viven en escalas distintas (por ejemplo C_{Jev} y $C_{\text{máx}}$), el número no viaja aunque el mapa sí: existe traducción exacta ϕ^{-1}. Si además pertenecen a clases distintas (por ejemplo $p_{\text{máx}}$ y la entropía), no existe ni número ni mapa, y el porte directo es una extrapolación inválida. Esta distinción, entre la capa de escala y la capa de forma, es la que explica por qué el resultado no se puede resumir con un promedio y se documenta en `docs/erratas_especificacion.md`.

III-E. Transferencia de umbrales (definición formal)

Dados un origen A, un destino B, una cobertura objetivo $q \in (0, 1)$ y un conjunto de calibración:

1. Hallar τ_A tal que $\text{cobertura}_A(\tau_A) = q$, con $\text{cobertura}_A(\tau) = \#\{C_A \geq \tau\}/N$ (el menor umbral observado que no supera la cobertura objetivo).
2. Portarlo al destino de una de dos maneras:
   - porte directo: $\tau_B := \tau_A$, que es lo que practica el ecosistema;
   - porte con mapa: $\tau_B := \psi(\tau_A)$, con ψ el mapa cerrado $A \to B$, que solo existe dentro de una clase de equivalencia y a cardinalidad fija (por ejemplo $\psi = \phi^{-1}$ para `jev` $\to$ `pmax`).
3. Medir en el conjunto de prueba la cobertura efectiva $\text{cobertura}_B(\tau_A)$ y la precisión.

La degradación $\Delta(A \to B) = q - \text{cobertura}_B(\tau_A)$ es la celda de la matriz. Se repite por modelo, por dataset y por cardinalidad. El mismo procedimiento se puede aplicar entre datasets (umbral ajustado en un dataset A y aplicado en otro B), que es el eje donde [14] observó que la calibración no viaja y [35] lo cuantificó dentro de la definición $p_{\text{máx}}$. Este trabajo recorre el eje distinto, el de las definiciones.

III-F. Predicción selectiva: el umbral como política

Con probabilidad de acierto p, coste de error C_{err} y coste de escalar C_{esc}, actuar conviene si $(1-p) \cdot C_{\text{err}} < C_{\text{esc}}$, es decir $p > 1 - C_{\text{esc}}/C_{\text{err}}$ [10]. Esta frontera presupone que p es una probabilidad calibrada. Cuando el umbral se elige como cuantil de una `confidence` mal especificada, la política efectiva deja de ser la óptima para el coste real: la métrica de la matriz es, en el fondo, la pérdida de utilidad del despliegue.

III-G. Nota sobre RLCD

RLCD (ruido gaussiano de media cero en los logits, regla estrictamente propia, REINFORCE con baseline de grupo, temperatura post-hoc) es el mecanismo que produce estas `confidence`. La teoría garantiza que reportar honestamente es el óptimo bajo una regla propia [18]; el análisis de septiembre de 2026 muestra que, en la práctica, el término RL equivale al gradiente de una cross-entropy suavizada con ruido, de modo que la inferencia sin ruido sale sobre-confiada [30], [31]. Esto explica por qué hace falta medir la calibración, pero no es el objeto de este trabajo: aquí no se propone un objetivo

Tabla IV
LAS CINCO CONFIGURACIONES DE PESOS ABIERTOS MEDIDAS. TODAS VERIFICAN `OUTPUT_TOKENS` = 0 (NO GENERAN TEXTO); LA ÚLTIMA ES UN CONTROL CRUDO, NO ENTRENADO PARA EMITIR DECISIONES.

configuración	familia	parámetros	papel
`convaiinnovations/laya`	encoder ModernBERT-large + cabeza de decisión	421M	implementación de referencia
`convaiinnovations/laya`, subcarpeta `typed-decisions`	el mismo repositorio, ajustado al benchmark	421M	variante afinada
`convaiinnovations/laya`, subcarpeta `multilingual`	el mismo repositorio, encoder multilingüe	n.d.	multilingüe
`jaredpalmer/kev-0.8b`	familia Kev (0.8B)	0.8B	familia entrenable
`Qwen/Qwen3.5-0.8B-Base`	Qwen, sin ajuste a decisiones	0.8B	**control crudo** (nivel `raw`)

Tabla V
DATASETS USADOS, CON SU CARDINALIDAD n Y EL NÚMERO DE ÍTEMS MEDIDOS. LOS CINCO ESTÁN YA ETIQUETADOS: NO HUBO ANOTACIÓN HUMANA.

dataset	n (cardinalidad)	ítems	por qué
`LocalLLaMA/typed-decisions`	2, 4, 5	2 000	el benchmark compartido del ecosistema
`SetFit/sst5`	5	1 101	ordinal (primitivo `score`)
`alisawuffles/WANLI`	3	5 000	inferencia de lenguaje natural
`mteb/banking77`	77	3 076	cardinalidad alta
`clinc/clinc_oos` (`plus`)	151	3 100	extremo de cardinalidad (el límite documentado de Jev)

de entrenamiento, se construye el instrumento que mide su resultado.

IV. MÉTODO

Desviaciones declaradas. El pre-registro exige reportarlas y están en `results/matrix/RESUMEN_MATRIZ.md` §7. La única con efecto sobre los datos es la D1: al auditar el pipeline se encontró que la implementación del debiasing `L0` no convergía (paso $\approx 1000\times$ demasiado pequeño), de modo que ese nivel era indistinguible de `raw`; se corrigió y las celdas `L0` se recalcularon. El nivel principal `raw` — sobre el que van todos los titulares — no se tocó tras publicar el pre-registro. D2 (un archivo contaminado del piloto, descartado) y D3 (`clinc150` no ejecutable en un checkpoint) no afectan a la confirmatoria.

IV-A. Modelos bajo medición

Se midieron cinco configuraciones de pesos abiertos, todas con `output_tokens` = 0 verificado (no generan texto). La revisión exacta de cada una (sha del Hub) quedó registrada por grupo en `results/crudos/*.meta.json` y en `results/raw/paso0_versions.json` (regla D4; Tabla IV).

El control crudo es deliberado: permite ver la transferencia en un modelo que no fue entrenado para emitir decisiones, y así separar lo que aporta el entrenamiento de lo que es propio del *readout*.

IV-B. Datasets

Todos ya etiquetados. No hubo anotación, etiquetado humano ni kappa (regla D2; Tabla V).

Cinco configuraciones por cinco datasets dan 25 combinaciones posibles; se midieron 23 grupos. Las dos ausencias no son fallos del pipeline y se declaran en §4.7.

Decisiones totales medidas: 65 185 (una fila por modelo, dataset e ítem), en `results/crudos/*.jsonl`.

IV-C. Las definiciones bajo medición

Sobre la distribución p que cada modelo devuelve para cada ítem se calcularon, en paralelo y con el mismo dato, las cuatro definiciones analíticas de la especificación (`paper/03_especificacion_confidence.md`):

$C_{\text{máx}} = p_{\text{máx}}$ (DEF-4) · $C_{\text{Jev}} = (n \cdot p_{\text{máx}} - 1)/(n-1)$ (DEF-1) · $C_{\text{ent}} = 1 - H(p)/\ln n$ (DEF-2) · $C_{\text{mar}} = p_{(1)} - p_{(2)}$ (DEF-5). La quinta, $C_{\text{noul}} = \text{máx}(\pi, 1-\pi)$ (DEF-3), entra en el bloque de $n = 2$.

Las dos definiciones opacas (`act_probability` de Laya y `open-decision-ai`) quedaron fuera de la matriz por decisión de alcance: no son funciones de p y no tienen clase de equivalencia en orden. Las transformaciones AnyJev (nivel `L0`, debiasing sin etiquetas; nivel `L1`, temperatura ajustada solo dentro de la partición de calibración) se aplicaron sobre las cuatro analíticas, además del nivel `raw`.

IV-D. Procedimiento

1. Cross-fitting $K = 5$, semilla `20261008`. El fold de cada ítem es determinista, `fold = sha256("20261008:id") mod 5`. El umbral se ajusta en cuatro folds y se evalúa en el que queda, de modo que cada ítem pasa por prueba exactamente una vez y ningún ítem participa en su propio umbral.
2. Umbral objetivo. Para un origen A y una cobertura objetivo q, se toma $\tau_A = \min\{\tau : \text{cobertura}(\tau) \le q\}$ sobre los valores observados de C_A en calibración, con $\text{cobertura}(\tau) = \#\{C_A \ge \tau\}/N$.
3. Dos portes por celda. El porte directo aplica $\tau_B := \tau_A$ tal cual, que es lo que practica el ecosistema, y su degradación es la métrica principal, $\Delta(A \to B) = q - \text{cobertura}_B(\tau_A)$. El porte con mapa aplica $\tau_B := \psi(\tau_A)$, con ψ el mapa cerrado $A \to B$ (por ejemplo $\psi = \phi^{-1}$ para jev $\to$ pmax), y existe solo dentro de una clase de equivalencia y a cardinalidad fija. El par de columnas es necesario porque el número y el mapa son cosas distintas (ver erratas E1 y E2 en `docs/erratas_especificacion.md`).
4. Coberturas objetivo $q \in \{0{,}80, 0{,}50, 0{,}95\}$, con 0.80 como principal.
5. Intervalos. Bootstrap de ítems con $B = 2000$ y semilla fija; el umbral τ no se reajusta dentro del bootstrap.
6. Comparaciones múltiples. Benjamini-Hochberg (FDR) con $\alpha = 0{,}05$ sobre todas las celdas.
7. Reporte por cardinalidad n y por nivel AnyJev.

Una celda de la matriz es, por tanto, la tupla (definición origen A, definición destino B, modelo, dataset, n, q, nivel). El resultado completo tiene 3 564 celdas, en `results/matrix/matriz_transferencia.csv`.

IV-E. *La figura central y los artefactos*

La matriz se resume en un mapa de calor por dataset y cardinalidad (`results/matrix/heatmap_*.png` y `.pdf`), con filas de definición origen y columnas de definición destino, y la caída de cobertura anotada por celda. La figura `delta_vs_delta_mapa_raw_q80` contrasta, celda a celda, el porte directo contra el porte con mapa (el enunciado de la Proposición 1 sobre los datos).

Todo el informe de resultados (`results/matrix/RESUMEN_MATRIZ.md`) se regenera con un comando, sin edición manual:

```
python -m pytest tests/ -q
python src/matriz/matriz.py -crudos results/
crudos -out results/matrix
python src/matriz/figura.py
python src/matriz/informe_matriz.py
```

`matriz.py` es CPU pura: lee los `.jsonl` de mediciones y no toca ningún peso. Si el CSV regenerado no es idéntico al publicado, hay un bug o un cambio de versión.

IV-F. *Trazabilidad (regla D4)*

Cada fila de `results/crudos/*.jsonl` contiene la distribución completa, la etiqueta, el acierto, las cuatro definiciones calculadas, el modelo, la revisión del Hub y un `row_hash`. La columna medido aquí agrupa los campos `conf_*` (calculados aquí sobre la distribución devuelta); la columna auto-reportado agrupa `answer_confidence`, `confidence_reported` y `act_probability` (emitidos por el propio modelo). Las cifras de ECE de las fichas del ecosistema son auto-reportadas y no se usan como medición propia.

IV-G. *Alcance no cubierto, declarado antes de los resultados*

- `clinc150` ($n = 151$) no es ejecutable en el checkpoint base de Laya: su ventana de 512 tokens solo admite 126 de las 151 opciones. El límite documentado de Jev (hasta 255 opciones) no es alcanzable en esa implementación. Sí se midió con los otros checkpoints y con el control crudo.
- `jaredpalmer/kev-suites` no carga (fallo de generación en el Hub el 08-oct-2026); no es un fallo del pipeline.
- Los modelos de 4B a 9B (Jeff-1, SemIf, jev-lite, Nimble-9B) no caben en 6 GB de VRAM; quedan como extensión en el Mac Mini o a 4 bits.

V. Resultados

V-A. *Qué se midió*

23 grupos, 65 185 decisiones, 3 564 celdas. El detalle por modelo y dataset (Tabla VI):

Un dato aparte, que el ecosistema no reporta: en cardinalidad alta, Kev-0.8B obtiene 0.813 de accuracy en `banking77` ($n = 77$) frente a 0.377 del checkpoint base de Laya, un factor de 2.2 (Fig. 1). Las cinco configuraciones medidas cubren el rango completo: del 0.016 del control sin entrenamiento al 0.813 de Kev-0.8B.

Tabla VI
Los 23 grupos medidos: cada fila cruza un modelo con un dataset, con su cardinalidad n, el número de ítems y la accuracy observada. La última columna confirma `OUTPUT_TOKENS` $= 0$ en todos los casos, es decir, ninguno genera texto.

modelo	dataset	n	ítems	accuracy	tokens
`Qwen/Qwen3.5-0.8B-Base`	`banking77`	77	3 076	0.0156	0
`Qwen/Qwen3.5-0.8B-Base`	`clinc150`	151	3 100	0.0387	0
`Qwen/Qwen3.5-0.8B-Base`	`sst5`	5	1 101	0.2116	0
`Qwen/Qwen3.5-0.8B-Base`	`typed-decisions`	2, 4, 5	2 000	0.4860	0
`Qwen/Qwen3.5-0.8B-Base`	`wanli`	3	5 000	0.3598	0
`convaiinnovations/laya`	`banking77`	77	3 076	0.3765	0
`convaiinnovations/laya`	`sst5`	5	1 101	0.3451	0
`convaiinnovations/laya`	`typed-decisions`	2, 4, 5	2 000	0.3595	0
`convaiinnovations/laya`	`wanli`	3	5 000	0.6178	0
`convaiinnovations/laya/multilingual`	`banking77`	77	3 076	0.3560	0
`convaiinnovations/laya/multilingual`	`clinc150`	151	3 100	0.6274	0
`convaiinnovations/laya/multilingual`	`sst5`	5	1 101	0.2489	0
`convaiinnovations/laya/multilingual`	`typed-decisions`	2, 4, 5	2 000	0.3515	0
`convaiinnovations/laya/multilingual`	`wanli`	3	5 000	0.5750	0
`convaiinnovations/laya/typed-decisions`	`banking77`	77	3 076	0.3781	0
`convaiinnovations/laya/typed-decisions`	`clinc150`	151	3 100	0.4732	0
`convaiinnovations/laya/typed-decisions`	`sst5`	5	1 101	0.4505	0
`convaiinnovations/laya/typed-decisions`	`typed-decisions`	2, 4, 5	2 000	0.7685	0
`convaiinnovations/laya/typed-decisions`	`wanli`	3	5 000	0.6190	0
`jaredpalmer/kev-0.8b`	`banking77`	77	3 076	0.8134	0
`jaredpalmer/kev-0.8b`	`sst5`	5	1 101	0.4995	0
`jaredpalmer/kev-0.8b`	`typed-decisions`	2, 4, 5	2 000	0.4595	0
`jaredpalmer/kev-0.8b`	`wanli`	3	5 000	0.5954	0

V-B. *Brecha entre definiciones sobre las 65 185 distribuciones*

Sobre las 65 185 distribuciones medidas (una fila por decisión), la diferencia entre la definición de `confidence` más alta y la más baja de la misma distribución tiene los valores de la Tabla VII:

En el caso típico, dos implementaciones del mismo campo discrepan en casi tres décimas sobre el mismo dato, y el peor caso llega a 0.85; cualquier umbral fijado sobre una de las dos no significa lo mismo sobre la otra (Fig. 2).

V-C. *Porte directo frente a porte con mapa cerrado*

El resultado principal corresponde al nivel `raw`, que es el que congela el pre-registro. En él, de las 3 564 celdas, 348 tienen mapa cerrado entre definiciones (misma clase de equivalencia

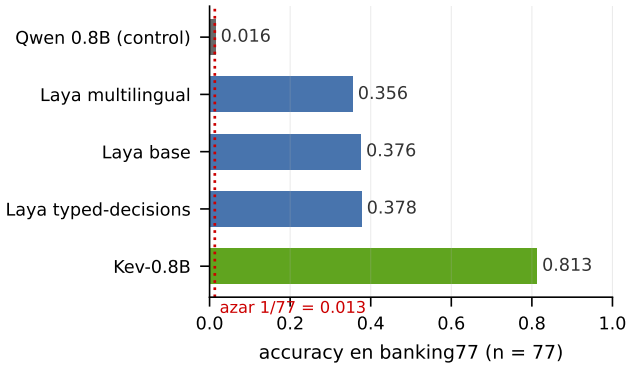


Figura 1. Accuracy en `banking77` ($n = 77$) de las cinco configuraciones medidas. La línea punteada marca el azar ($1/77 = 0{,}013$); el control sin entrenamiento cae sobre ella.

Tabla VII
BRECHA INTERNA DE `CONFIDENCE` SOBRE LAS 65 185 DISTRIBUCIONES MEDIDAS: DIFERENCIA ENTRE LA DEFINICIÓN MÁS ALTA Y LA MÁS BAJA DE UNA *misma* DISTRIBUCIÓN.

estadístico	valor
mediana	**0.288**
percentil 90	**0.434**
máximo	**0.848**

y misma cardinalidad; 1 044 si se cuentan los tres niveles), que son las únicas donde tiene sentido comparar el porte directo contra el porte con mapa. El error absoluto medio está en la Tabla VIII:

El porte directo se equivoca 109 veces más que el porte con mapa en el subconjunto sin empates dominantes (0.2337 frente a 0.0021) y 20 veces más sobre todas las celdas (0.2528 frente a 0.0123). La causa de esa diferencia es el suelo que imponen los empates del umbral, que se detalla más abajo (Fig. 3).

El suelo de los empates. El porte con mapa tiene un suelo que no es culpa del mapa: si el umbral cae sobre un valor empatado en muchas salidas (modelos saturados), la cobertura salta y ni el mapa puede dar q exacto. Por eso la comparación limpia es la del subconjunto sin empates dominantes (masa por debajo del 5 %), y por eso `delta_mapa` debe leerse contra `delta` de la misma celda, nunca como un cero absoluto. La columna `n_empates_tau` de la matriz declara, en cada celda, cuántos ítems comparten el umbral (Fig. 4).

V-D. Caída de cobertura por par de definiciones

La distribución de Δ es bimodal: hay pares de definiciones que coinciden y pares que fallan en grande (Tabla IX). Por eso la unidad de análisis es el par y no la media global.

Dos de las coincidencias son identidades matemáticas, no azar: (i) a $n = 2$, C_{jev} y C_{mar} son la misma función $(2 \cdot p_{\text{máx}} - 1)$, así que su porte directo ya da casi cero; (ii) a cardinalidad alta, $C_{\text{jev}} = (n \cdot p - 1)/(n - 1) \to p$, así que `jev` y `pmax` convergen y sus umbrales casi coinciden. En el extremo opuesto,

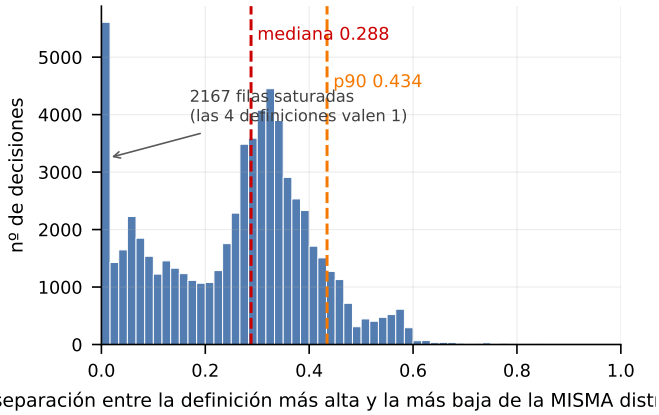


Figura 2. Distribución de la brecha entre la definición más alta y la más baja de cada distribución, sobre las 65 185 decisiones medidas (mediana 0.288, p90 0.434, máximo 0.848). El pico en cero son las 2 167 filas saturadas, en las que las cuatro definiciones valen 1.

Tabla VIII
ERROR ABSOLUTO MEDIO DEL PORTE DIRECTO FRENTE AL PORTE CON MAPA, POR SUBCONJUNTO DE CELDAS (NIVEL `RAW`). EL PORTE DIRECTO SE EQUIVOCA HASTA DOS ÓRDENES DE MAGNITUD MÁS QUE EL PORTE CON MAPA.

subconjunto	celdas	$\lvert\Delta\rvert$ directo	$\lvert\Delta\rvert$ con mapa	factor
todas las celdas con mapa	348	0.2528	0.0123	20.5×
sin empates dominantes en el umbral	**312**	**0.2337**	**0.0021**	**109.2×**
solo modelos entrenados (sin control crudo)	276	0.2289	0.0020	112.8×
solo $n = 2$ (Proposición 3)	180	0.3006	0.0218	13.8×
solo $n \geq 3$ (Proposición 1)	168	0.2015	0.0021	95.8×
nivel `L0` (debiasing sin etiquetas)	324	0.2190	0.0059	37.1×
nivel `L1` (temperatura con etiquetas)	312	0.3022	0.0024	126.0×

pmax → ent es el peor par: no cambia la escala, cambia la forma de la función (Fig. 5).

Fracción de celdas que transfieren bien ($\lvert\Delta\rvert < 0{,}01$), por cardinalidad y nivel `raw` (Tabla X):

V-E. Efecto de la cardinalidad

La Tabla XI desglosa la caída de cobertura y las celdas que sobreviven al control de FDR en cada cardinalidad, con el dataset de ejemplo correspondiente.

El porte falla en todas las cardinalidades, con dos matices: a n bajo el daño es grande y sistemático, mientras que a cardinalidad alta ($n \geq 77$) las definiciones tipo $p_{\text{máx}}$ convergen entre sí y una parte de las celdas transfiere bien (Fig. 6). La Proposición 3 predice que con $n = 2$ todas las definiciones deberían ser equivalentes en orden; en los datos eso se cumple dentro del par jev ↔ margin (misma función) y no en el resto, porque el porte directo cruza escalas distintas aunque el orden sea el mismo (Sección III).

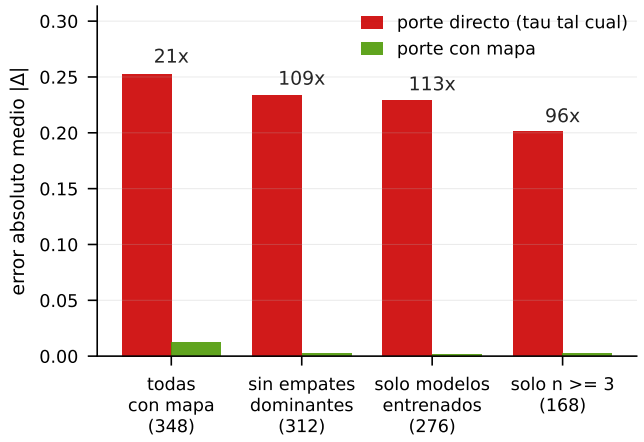


Figura 3. $|\Delta|$ medio del porte directo (τ tal cual) y del porte con mapa cerrado, por subconjunto de celdas del nivel `raw` con las tres q. Entre paréntesis, la cantidad de celdas; sobre cada par, la razón entre ambas barras. Las celdas sin empates dominantes son la comparación limpia (0.2337 frente a 0.0021, 109×).

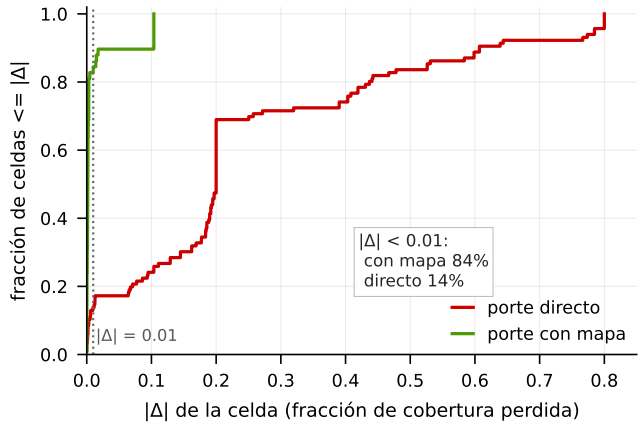


Figura 4. Función de distribución empírica de $|\Delta|$ en las 116 celdas con mapa cerrado del nivel `raw` con $q = 0{,}80$. La línea vertical marca $|\Delta| = 0{,}01$: por debajo quedan el 84 % de las celdas con porte con mapa y el 14 % con porte directo.

V-F. Celdas sin transferencia tras FDR (nivel `raw`, $q = 0{,}80$)

Hay celdas en las que portar el umbral pierde toda la cobertura (Tabla XII). Quien calibra al 80 % con una definición y despliega con otra puede terminar actuando en el 0 % de los casos (o en todos), sin ningún aviso del modelo. La Fig. 7 muestra la matriz completa en el dataset de cardinalidad alta.

V-G. Hallazgos de metrología del paso 0 (contexto)

La corrida de verificación sobre `typed-decisions` dejó, además, dos resultados que no estaban en la literatura del ecosistema y que son parte del instrumento:

1. La `choice_confidence` de Kev es la fórmula de Jev. $(p_{\text{máx}} - 1/K)/(1 - 1/K) \equiv (K \cdot p_{\text{máx}} - 1)/(K - 1)$, verificado numéricamente para $K \in \{2, 3, 4, 7, 12\}$. Estaban registradas como definiciones distintas; por la Proposición 1, ese par transfiere el umbral de forma exacta.
2. El campo `output_tokens` tiene tres significados. Jev y Laya lo reportan como 0 (no hay generación); Kev lo usa como recuento de tokens de la respuesta serializada (869 310 en las mismas 2 000 decisiones). Es metrología del propio campo, no un fallo de Kev.

Tabla IX
CAÍDA DE COBERTURA POR PAR DE DEFINICIONES (ORIGEN $A \to$ DESTINO B), ORDENADA POR LA MEDIANA. LA COLUMNA DE LA MEDIA MUESTRA POR QUÉ EL PROMEDIO GLOBAL NO DESCRIBE EL FENÓMENO.

$A \to B$	celdas	$\lvert\Delta\rvert$ mediana	$\lvert\Delta\rvert$ media	¿mapa?
`margin` → `jev`	15	**0.0023**	0.0250	sí
`jev` → `margin`	15	**0.0023**	0.0293	sí
`jev` → `pmax`	99	**0.0759**	0.1568	sí
`ent` → `jev`	15	**0.1837**	0.1898	sí
`ent` → `margin`	15	**0.1837**	0.1898	sí
`margin` → `pmax`	15	**0.2000**	0.2253	sí
`ent` → `pmax`	15	**0.2000**	0.2421	sí
`pmax` → `jev`	99	**0.2574**	0.2973	sí
`margin` → `ent`	15	**0.3474**	0.3855	sí
`jev` → `ent`	15	**0.3474**	0.3857	sí
`pmax` → `margin`	15	**0.5262**	0.5154	sí
`pmax` → `ent`	15	**0.7667**	0.6787	sí

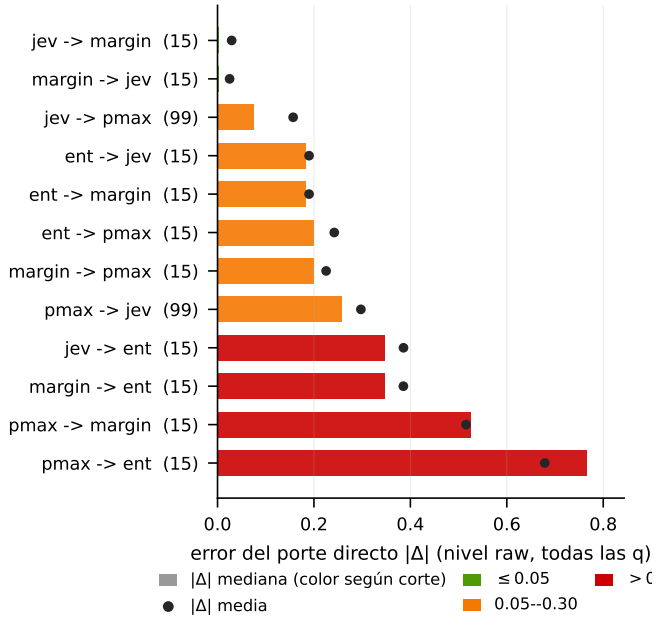


Figura 5. $|\Delta|$ mediana (barra) y media (punto) por par de definiciones del nivel `raw`, ordenadas por la mediana; entre paréntesis, la cantidad de celdas. El color separa los tres regímenes ($\leq 0{,}05$, 0,05–0,30, $> 0{,}30$). Los extremos son `margin`↔`jev` (0.0023) y `pmax`→`ent` (0.7667).

Y sobre la misma corrida, el ECE depende de la definición: en `laya-typed-decisions` va de 0.216 con $p_{\text{máx}}$ a 0.577 con la entropía normalizada, un factor 2.7 sobre el mismo dato. El patrón no es local: sobre los 23 grupos, la diferencia entre la mejor y la peor definición tiene mediana 0.124 y llega a 0.361, y la definición mejor calibrada cambia de grupo en

Tabla X
FRACCIÓN DE CELDAS QUE TRANSFIEREN BIEN ($|\Delta| < 0{,}01$) SEGÚN LA CARDINALIDAD n. EL UMBRAL VIAJA EN EL 63 % DE LAS CELDAS A $n = 77$ Y EN EL 44 % A $n = 151$.

n	celdas con mapa	$\lvert\Delta\rvert$ mediana	% con $\lvert\Delta\rvert < 0{,}01$
2	180	0.2141	14 %
3	30	0.1775	0 %
4	30	0.4085	0 %
5	60	0.2000	0 %
77	30	0.0058	63 %
151	18	0.0127	44 %

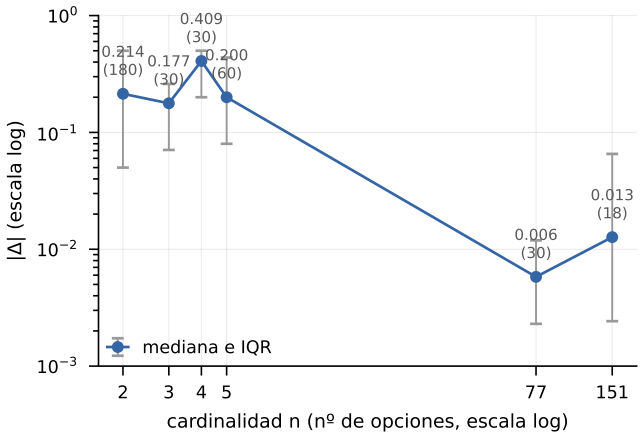


Figura 6. $|\Delta|$ mediana por cardinalidad en escala logarítmica, con el rango intercuartílico y la cantidad de celdas entre paréntesis (nivel `raw`, las tres q). El patrón no es monótono: 0.214, 0.178, 0.409 y 0.200 para $n \leq 5$, y 0.006 y 0.013 para $n \geq 77$.

Tabla XI
CAÍDA DE COBERTURA Y CELDAS SIGNIFICATIVAS TRAS FDR, POR CARDINALIDAD n, CON EL DATASET DE EJEMPLO. EL PORTE FALLA EN TODAS LAS CARDINALIDADES.

n	celdas	$\lvert\Delta\rvert$ medio	celdas con FDR	dataset de ejemplo
2	60	0.3042	52	`typed-decisions`
3	60	0.2011	60	`wanli`
4	60	0.3240	60	`typed-decisions`
5	120	0.2664	119	`sst5`
77	60	0.1638	52	`banking77`
151	36	0.2140	32	`clinc150`

Tabla XII
CELDAS DONDE EL UMBRAL NO VIAJA: NIVEL `RAW`, $q = 0{,}80$, TRAS FDR. PORTAR EL UMBRAL PIERDE TODA LA COBERTURA ($\Delta = 0{,}80$, COBERTURA B $= 0$) O CASI TODA.

modelo	dataset	n	$A \to B$	Δ	IC95 %	cobertura B
`Qwen/Qwen3.5-0.8B-Base`	`banking77`	77	`ent` → `margin`	0.8000	[0.800, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`sst5`	5	`pmax` → `ent`	0.8000	[0.800, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`typed-decisions`	2	`pmax` → `jev`	0.8000	[0.800, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`typed-decisions`	2	`pmax` → `ent`	0.8000	[0.800, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`typed-decisions`	2	`pmax` → `margin`	0.8000	[0.800, 0.800]	0.000
`convaiinnovations/laya/typed-decisions`	`typed-decisions`	2	`pmax` → `ent`	0.8000	[0.800, 0.800]	0.000
`jaredpalmer/kev-0.8b`	`typed-decisions`	2	`pmax` → `ent`	0.8000	[0.800, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`banking77`	77	`pmax` → `margin`	0.7997	[0.799, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`banking77`	77	`ent` → `jev`	0.7997	[0.799, 0.800]	0.000
`Qwen/Qwen3.5-0.8B-Base`	`banking77`	77	`jev` → `margin`	0.7993	[0.798, 0.800]	0.001
`Qwen/Qwen3.5-0.8B-Base`	`banking77`	77	`ent` → `pmax`	0.7990	[0.798, 0.800]	0.001
`Qwen/Qwen3.5-0.8B-Base`	`sst5`	5	`pmax` → `margin`	0.7974	[0.794, 0.800]	0.003

grupo ($p_{\text{máx}}$ en 7, `margin` en 6, `ent` en 6 y `jev` en 4), con la entropía normalizada como la peor en 13 de los 23 (Fig. 8).

V-H. Extensiones declaradas (posteriores al pre-registro)

Las cifras de las subsecciones anteriores están selladas por el pre-registro `10.5281/zenodo.23266795`: 23 grupos, 65 185 decisiones, 3 564 celdas. Las dos mediciones de esta subsección son posteriores a ese pre-registro y se declaran aparte para no moverlas: no recalculan la matriz sellada ni las filas crudas, se calculan como post-proceso sobre datos ya medidos o sobre un brazo nuevo, y llevan su fecha.

V-H1. Quinta definición del campo: `conf_score` (distancia al nivel modal): La documentación de TypeSafe define para la primitiva `score` una `confidence` que no estaba entre las cuatro definiciones selladas (Tabla XIII):

$$C_{\text{score}} = \text{máx}\Big(0,\ 1 - \tfrac{1}{M}\textstyle\sum_i p_i\,|i-m|\Big), \qquad M = \tfrac{1}{n}\textstyle\sum_i \big|i - \tfrac{n-1}{2}\big|, \tag{1}$$

donde M es la desviación absoluta media de la rejilla uniforme (*MAD* uniforme) y m el nivel modal. No es una variante de C_{jev}: C_{jev} mide concentración en el máximo; C_{score} mide dispersión alrededor del nivel modal. Dos distribuciones con el mismo $p_{\text{máx}}$ dan valores distintos. Y es ordinal: exige que los niveles tengan orden y distancia, así que solo se mide donde el orden existe.

Por qué solo `sst5`. En `banking77` (77), `clinc150` (151) y `typed-decisions` (2, 4, 5) las etiquetas son nominales: el índice i no significa nada y usarlo sería añadir un supuesto, no medir. En `wanli` (3) el orden es discutible. Se declara el límite en lugar de inventar la escala.

El hallazgo que añade. La quinta definición no tiene un sesgo estable: es la más baja de las cinco en el 70.3 % de las filas del control crudo Qwen y la más alta en el 92.6 % de las de Laya-multilingual. El signo de la discrepancia depende del modelo, no de la definición — que es exactamente el objeto de este trabajo, ahora con una definición más en la lista.

V-H2. Brazo pagado: el modelo detrás del campo: Hasta aquí todo se midió sobre pesos abiertos. El servicio real de TypeSafe (`jev-1.13.0`, una petición por ítem) se midió sobre los mismos cinco datasets y se publica como brazo aparte: 14 277 decisiones, gasto USD 0.79, con `probabilities` y `confidence` redondeadas a 0.01 por el servicio (Tabla XIV).

Dos observaciones de metrología del propio campo. (i) El contador `output_tokens` no es cero en el servicio (7 092 972 en total), a diferencia de los brazos de pesos abiertos: el campo *tokens de salida* no distingue por sí solo un modelo de decisión de uno generativo; esa lectura solo vale donde se controla la implementación. (ii) La confianza

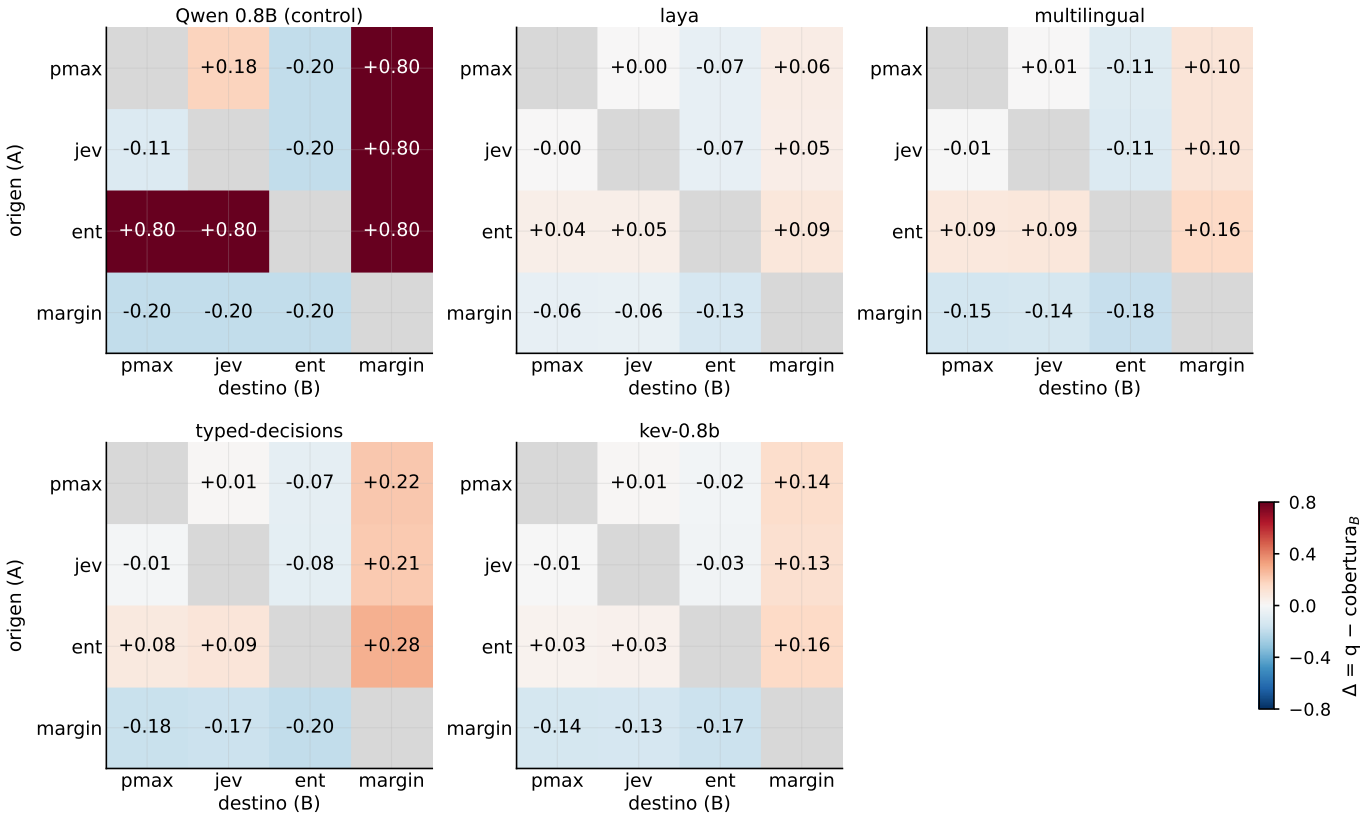


Figura 7. $\Delta = q - \text{cobertura}_B$ al portar τ sin mapa en `banking77` ($n = 77$, nivel `raw`, $q = 0{,}80$): filas de definición origen, columnas de definición destino y escala de color compartida entre los cinco paneles; la diagonal no aplica. En el control Qwen, usar `ent` como origen pierde toda la cobertura ($\Delta = +0{,}80$) sea cual sea el destino, y lo inverso ocurre con `margin` ($\Delta = -0{,}20$, sobre-cobertura).

Tabla XIII
LA QUINTA DEFINICIÓN SOBRE `sst5` (5 NIVELES ORDINALES, 5 CONFIGURACIONES, 5 505 DECISIONES). LA BRECHA ES LA DIFERENCIA ENTRE LA DEFINICIÓN MÁS ALTA Y LA MÁS BAJA DE LA *misma* DISTRIBUCIÓN; EL ECE SE CALCULA SOBRE LA MISMA CORRIDA Y LA MISMA ETIQUETA DE CORRECCIÓN QUE LAS OTRAS CUATRO.

Brecha, mediana con 4 definiciones	0.272
Brecha, mediana con 5 definiciones	**0.290** (p90 0.411, máx 0.581)
ECE global, C_{pmax}	0.204
ECE global, C_{jev}	0.184
ECE global, C_{ent}	0.199
ECE global, C_{mar}	0.237
ECE global, C_{score}	**0.241**
Verificación contra el servicio real	$\lvert\Delta\rvert \le 0{,}0050$ en 800 filas

Tabla XIV
BRAZO PAGADO: EL SERVICIO REAL SOBRE LOS CINCO DATASETS ETIQUETADOS. LA ÚLTIMA COLUMNA ES EL CONTADOR `output_tokens` QUE REPORTA EL SERVICIO; EN TODOS LOS BRAZOS DE PESOS ABIERTOS ESE MISMO CONTADOR VALE CERO.

dataset	n	ítems	accuracy	tokens de salida
`banking77`	77	3 076	0.796	2 547 728
`clinc150`	151	3 100	0.901	4 034 486
`sst5`	5	1 101	0.541	19 818
`typed-decisions`	2, 4, 5	2 000	0.733	270 290
`wanli`	3	5 000	0.754	220 650

que el servicio devuelve coincide con la definición que la especificación le asigna a cada primitiva: C_{score} en las filas `score` ($\lvert\Delta\rvert \le 0{,}0050$ sobre 800 filas) y C_{jev} en las de `choice` (600 filas). La especificación describe el servicio real, no una reconstrucción.

Sumado a los brazos abiertos, el conjunto tiene 79 462 decisiones y una brecha mediana de 0.273 (p90 0.435) — el mismo orden que la cifra sellada de 0.288, ahora con seis modelos.

El porte del umbral con la rejilla de 0.01. Error absoluto medio del porte sobre las celdas con mapa cerrado (nivel `raw`, las tres q; 420 celdas; Tabla XV):

El resultado se lee en dos partes, y la segunda corrige la intuición. (i) El porte directo de Jev (0.1735) es de los mejores, pero no el mejor: el checkpoint `laya/multilingual` transfiere mejor (0.1315) sin ser el modelo de referencia del campo. Comparar $\lvert\Delta\rvert$ directo entre modelos mezcla dos causas —la definición y la calidad del modelo— y por eso la unidad de análisis de este trabajo es el par de definiciones, no el modelo. (ii) El porte con mapa de Jev es 4.6 a 9.3 veces el de los checkpoints abiertos (0.0130 frente a 0.0014–0.0028) y su factor directo/mapa es 13.4×, un orden de magnitud menor que el de ellos (75–174×). La causa está medida: la rejilla

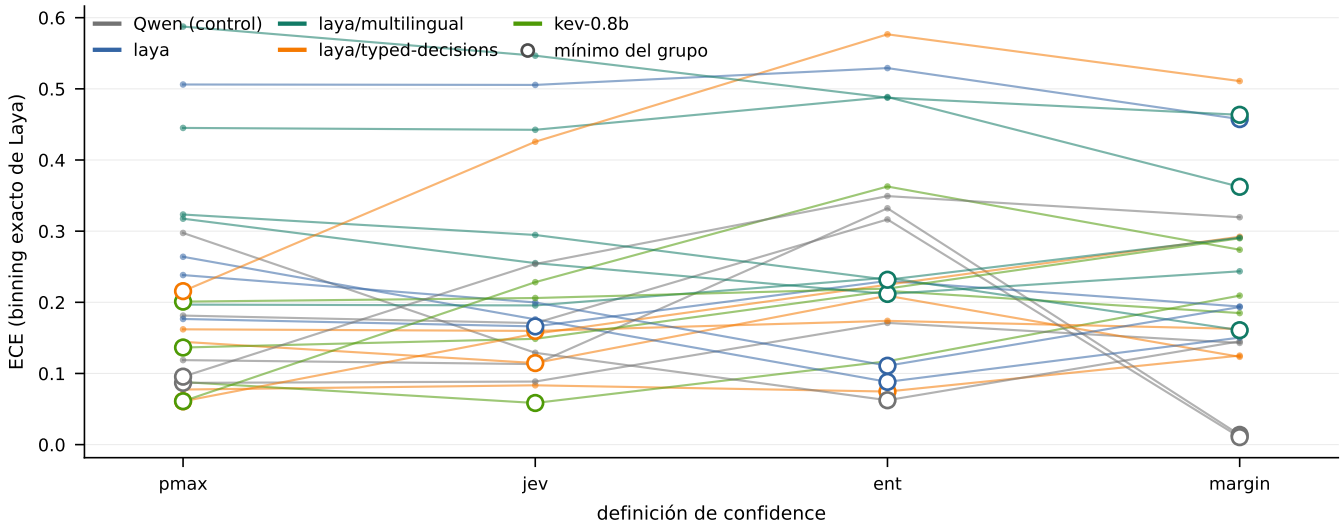


Figura 8. ECE de las cuatro definiciones en los 23 grupos medidos, calculado sobre las mismas filas crudas. El círculo hueco marca la definición con menor ECE de cada grupo: cambia de grupo en grupo y ninguna definición es la mejor calibrada en todos.

Tabla XV
PORTE DEL UMBRAL EN EL CONJUNTO COMBINADO, POR MODELO. LA ÚLTIMA COLUMNA ES LA FRACCIÓN MEDIA DE ÍTEMS DE PRUEBA QUE COMPARTEN EL UMBRAL (EMPATES INDUCIDOS POR LA REJILLA DE 0.01 DEL SERVICIO).

modelo	celdas	$\|\Delta\|$ directo	$\|\Delta\|$ con mapa	factor
`typesafe-ai/jev`	72	0.1735	**0.0130**	13.4×
`laya/multilingual`	72	**0.1315**	0.0018	75.1×
`laya`	66	0.2581	0.0028	91.7×
`laya/typed-decisions`	72	0.2515	0.0014	174.4×
`kev-0.8b`	66	0.2813	0.0022	128.5×
`Qwen3.5-0.8B` (control)	72	0.3441	0.0517	6.7×
global	420	0.2392	0.0124	19.3×

de 0.01 reasigna masa a valores empatados y 2.5 % de los ítems de prueba de Jev comparten el umbral, frente a 0.1 % en los abiertos (25×), con 4 de 72 celdas por encima del 5 % de empate frente a 0 en las abiertas. El mapa cerrado sigue siendo válido (Proposición 1); lo que la rejilla degrada es la resolución del umbral, no la equivalencia entre definiciones.

Fuentes: `results/matrix/EXTENSION_CONF_SCORE.md` y `results/matrix_pagado/RESUMEN_MATRIZ_PAGADO.md`; se regeneran con `src/matriz/extension_conf_score.py` y `src/matriz/correr_matriz_pagado.sh`. Ninguna de estas dos extensiones modifica el nivel `raw` sellado, ni las 3 564 celdas, ni las 65 185 filas crudas.

VI. DISCUSIÓN

VI-A. *El hallazgo tiene dos capas*

El resultado principal es que un umbral de `confidence` no transfiere entre implementaciones y que el promedio no describe el fenómeno. Al mirar celda a celda aparecen dos capas distintas, y confundirlas lleva a conclusiones opuestas (documentado en `docs/erratas_especificacion.md`, E2).

Capa 1, la escala. Dos definiciones pueden ordenar las decisiones igual y aun así estar en escalas distintas. $C_{\text{máx}} = p$ y $C_{\text{Jev}} = (n \cdot p - 1)/(n - 1)$ inducen el mismo umbral en orden, de modo que existe un mapa cerrado $\psi = \phi^{-1}$ entre ellas. El número no viaja ($|\Delta|$ mediano de 0.20 a 0.31 en el par `pmax` ↔ `jev`), pero el mapa sí transfiere (0.0025): la escala se corrige, la cifra no sirve tal cual.

Capa 2, la forma. Entre definiciones de clases distintas ($p_{\text{máx}}$, entropía, margen) no existe ni número ni mapa. `pmax` → `ent` tiene mediana de 0.77: es el caso en que la confianza «alta» de una definición y la de la otra ordenan las decisiones de forma diferente, no solo con otra escala. Aquí no hay nada que traducir y el porte directo es lisa y llanamente una extrapolación inválida.

La coexistencia de las dos capas es la razón de que el resultado no se pueda resumir con una media: la misma tabla contiene identidades exactas (14 % de las celdas con $n = 2$ transfieren bien) y desastres (celdas con $\Delta = 0{,}80$ y cobertura 0).

VI-B. *Por qué el orden se preserva y el número no*

Sea f una transformación creciente de $p_{\text{máx}}$. Un umbral τ sobre $f(p_{\text{máx}})$ selecciona el mismo conjunto de decisiones que el umbral $f^{-1}(\tau)$ sobre $p_{\text{máx}}$, porque f monótona no cambia el orden. Por eso C_{Jev}, $C_{\text{máx}}$ y C_{mar} (fijado n) seleccionan lo mismo con el umbral traducido. Pero el valor de f depende de n y de la definición, así que la misma cifra 0,7 significa coberturas distintas. Y cuando f deja de ser una función de $p_{\text{máx}}$ (la entropía usa toda la distribución, no solo el máximo), ni siquiera existe el mapa.

Esto es exactamente lo que predice la Proposición 1 y lo que mide el factor 109×: el costo de confundir «mismo orden» con «mismo número».

VI-C. El umbral es una política, no un número suelto

En un sistema que decide, el umbral no es un parámetro cosmético: define cuándo el modelo actúa y cuándo se abstiene. Un umbral trasladado sin mapa no solo cambia una métrica de calibración, cambia la política de abstención. Las celdas de §5.6 lo muestran en su forma extrema: con $q = 0{,}80$ puede terminar actuando en el 0 % de los casos. Para quien integra un modelo tipo Jev, la conclusión práctica es que el campo `confidence` no es un contrato entre implementaciones: es un número local, válido dentro de la definición que lo produjo.

Y sin embargo el ecosistema lo trata como si lo fuera. La revisión de implementaciones (Kev, Laya, AnyJev, open-decision-ai) muestra que cada una publica su fórmula bajo el mismo nombre y que ninguna documenta la relación con las demás. Ese vacío es el que este instrumento llena: no descubre que hay sobre-confianza (eso ya se midió puertas adentro de varias implementaciones), sino que cuantifica el error de trasladar el umbral entre ellas y entrega el mapa cuando existe.

VI-D. Calibración de las implementaciones medidas

La literatura reciente mide la calibración dentro de una definición (por ejemplo, ECE de Laya tal como se distribuye). Este trabajo mide entre definiciones, que es una pregunta distinta y hasta ahora sin tabla. Los dos resultados no se contradicen: un modelo puede estar bien calibrado respecto de su propia definición y aun así ser inutilizable como fuente de umbral para otra. La cifra de §5.7 (el ECE cambia 2.7× según la definición, sobre el mismo dato) ilustra que buena parte de las discrepancias que se atribuyen al modelo son, en realidad, discrepancias del medidor.

VI-E. Limitaciones

- Cobertura de modelos. Cinco configuraciones de hasta 0.8B, todas las que caben en 6 GB. Los modelos de 4B a 9B del ecosistema quedan como extensión declarada.
- Dos grupos ausentes. `clinc150` en el checkpoint base de Laya (ventana de 512 tokens, 126 de 151 opciones) y `kev-suites` (no carga en el Hub). Ninguno altera las conclusiones, pero acotan el alcance medido a 23 de 25 combinaciones.
- El mapa existe dentro de clases y a cardinalidad fija. Las celdas sin mapa (2 520 de 3 564) no son «fallos»: son el resultado de que no haya traducción matemática posible. La matriz las marca como tales.
- El control crudo infla el porte directo en las celdas con empates de umbral (modelo sin entrenar, salidas saturadas). Por eso la comparación limpia excluye las celdas dominadas por empates y la de referencia es la de 312 celdas (109×, nivel `raw`).
- Las definiciones opacas (`act_probability`, `open-decision-ai`) quedaron fuera de la matriz por decisión de alcance, ya que no son funciones de la distribución.

VI-F. Relación con los trabajos previos

Este resultado es un instrumento, y se sostiene aunque otro publique un hallazgo cercano. La calibración de un modelo puntual (por ejemplo, la medición de Laya tal cual se distribuye) es un hallazgo fechado; la matriz de transferencia y la librería que la reproduce son infraestructura. El instrumento no compite con esa literatura: la cita, la usa como punto de partida y la extiende al eje que le faltaba, el eje entre definiciones.

Las demás aristas del eje (por qué el término de RL no induce calibración, la ablación del objetivo de entrenamiento, la cartografía del ecosistema, la coherencia frente a la negación) están ocupadas por trabajos recientes y quedan fuera de esta tesis. Aquí lo medido es, deliberadamente, el hueco que quedaba abierto: la transferencia de umbrales entre definiciones incompatibles del mismo campo.

VII. Conclusión y artefactos

VII-A. Conclusión

El ecosistema abierto de modelos de decisión tipo Jev comparte un nombre de campo, `confidence`, y una promesa: que sirve para fijar un umbral de actuación. La medición sobre 23 grupos, 65 185 decisiones y 3 564 celdas muestra que esa promesa no viaja entre implementaciones. Sobre la misma distribución, la definición de `confidence` más alta y la más baja difieren con mediana 0.288 y máximo 0.848. Portar el umbral tal cual (copiar la cifra) se equivoca del orden de cien veces más que portarlo con el mapa matemático cuando este existe (0.2337 contra 0.0021, sobre las 312 celdas del nivel principal `raw` sin empates dominantes). Y en las celdas de peor caso, el porte directo pierde toda la cobertura: quien calibra al 80 % con una definición puede terminar actuando en el 0 % con otra.

El resultado tiene dos capas. La escala hace que el número no viaje aunque el orden se preserve; la forma hace que entre clases de definiciones distintas no exista ni número ni mapa. Dos pares que la documentación registra como definiciones distintas resultan ser la misma fórmula (la `choice_confidence` de Kev es la de Jev; con $n = 2$, C_{Jev} y el margen coinciden), lo que da transferencia exacta donde otros ven incompatibilidad.

El aporte no es el hallazgo de que las implementaciones discrepan, que era de esperar. El aporte es el instrumento que permite cuantificar y corregir esa discrepancia, y que sigue valiendo aunque cada premisa particular se cierre.

VII-B. Artefactos entregados

La Tabla XVI lista cada artefacto con su identificador y su estado.

Todo el conjunto se regenera con `python -m pytest tests/ -q` seguido de los tres scripts de `src/matriz/` (§4.5). Ninguna cifra del paper se escribe a mano: todas provienen del informe regenerable.

VII-C. Trabajo futuro

El arco completo tiene tres etapas, y esta tesis cubre la primera.

Tabla XVI
ARTEFACTOS ENTREGADOS

#	Artefacto (y dónde vive)	Estado
1	Especificación formal de las definiciones (DEF-1..DEF-8, Proposiciones 1 a 3) y erratas, en `paper/03_especificacion_confidence.md`	hecho
2	Librería `jev-conf-metrics`, en `src/jev_conf_metrics/`	hecho (67 tests)
3	Arnés de conformidad (tests T1..T8), en `tests/`	hecho
4	Matriz de transferencia de umbrales, en `results/matrix/matriz_transferencia.csv`	medida (3 564 celdas)
5	Dataset de mediciones crudas, en `results/crudos/`, con `row_hash` por fila	medido (65 185 filas)
6	Scripts regeneradores, en `src/matriz/`	hechos
7	Figuras (mapas de calor por dataset y cardinalidad), en `paper/figures/`	hechas
8	Pre-registro con DOI, en `paper/04_pre_registro.md` → Zenodo	publicado (`10.5281/zenodo.23266795`)
9	Repositorio `github.com/Arbues/tesis1-jev-confidence`	**público** (Apache-2.0 / CC-BY-4.0)
10	Extensión declarada: quinta definición del campo (`conf_score`), en `results/matrix/EXTENSION_CONF_SCORE.md`	medida (5 505 decisiones)
11	Extensión declarada: brazo pagado (API real `jev-1.13.0`), en `results/pagado/`	medido (14 277 decisiones)

- Tesis 1 (este trabajo, medida). El instrumento: medir y cuantificar la transferencia de umbrales entre las definiciones incompatibles del campo `confidence`.
- Tesis 2 (mecanismo). Una vez medido el problema, inducir calibración en el objetivo de entrenamiento, no solo por ajuste post-hoc. La pregunta heredada es por qué el término de RL de RLCD no bastó, que la literatura reciente ya exploró y que aquí se da por ocupada.
- Taller de Tesis (teoría). Las condiciones necesarias y suficientes para que una regla de puntuación estrictamente propia induzca un umbral que viaje entre definiciones.

Extensiones inmediatas del instrumento: medir los modelos de 4B a 9B en el Mac Mini, incorporar las definiciones opacas cuando exista una forma de tratarlas, y repetir la matriz cuando aparezcan nuevas implementaciones (el instrumento está diseñado para eso, no para un conjunto fijo de modelos).

VII-D. Disponibilidad

Repositorio público github.com/Arbues/tesis1-jev-confidence (Apache-2.0 el código, CC-BY-4.0 el paper y la documentación). El pre-registro con el diseño congelado tiene DOI 10.5281/zenodo.23266795.

REFERENCIAS

[1] TypeSafe AI, "Introducing system one models and jev," https://typesafe.ai/blog/introducing-system-one-models-and-jev, Sep. 2026, anuncio oficial, 18-sep-2026.

[2] ——, "Jev primitives documentation (choice, score, noul)," https://docs.typesafe.ai/primitives/choice, 2026.

[3] N. Mukkunnoth and Convai Innovations, "Laya: an open rlcd decision model," https://github.com/NandhaKishorM/laya & https://huggingface.co/convaiinnovations/laya, 2026, apache-2.0; 421M = ModernBERT-large + cabeza; pesos y receta.

[4] J. Palmer, "Kev: a jev-like family of trainable decision models," https://github.com/jaredpalmer/kev, 2026, apache-2.0; kev-0.8b entrena en 4 GB de VRAM.

[5] Bespoke Labs, "Nimble: data, model and recipe for an open jev," https://github.com/bespokelabsai/nimble, 2026.

[6] T. Lee *et al.*, "Semif-openjev," https://github.com/TheoLeeCJ/SemIf-OpenJev, 2026, mIT; temperatura por carga de trabajo con ECE fuera de muestra.

[7] Gestalt Labs, "Jeff-1: a lora decision model compared live against jev," https://github.com/Gestalt-Lab/jeff & https://huggingface.co/GestaltLabs/Jeff-1, 2026, 9.730 filas humanas; Jeff 0.8183 vs Jev 0.8283; ECE 0.0807 vs 0.0932.

[8] V. Anand, "jev-lite: Qlora over gemma 4 e4b," https://huggingface.co/vagmi/jev-lite, 2026, eCE 0.019; p_max gana a la entropía normalizada (AUROC 0.816); repo sin licencia.

[9] Nokia Applied Research, "Anyjev: a training-free layer that turns any open llm into a calibrated decision model," https://pypi.org/project/anyjev/, 2026, apache-2.0; niveles raw/L0/L1.

[10] C. K. Chow, "On optimum recognition error and reject tradeoff," *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.

[11] Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[12] Laya Studio, "Entropy-based confidence: definition (laya studio docs)," https://laya.studio/glossary/entropy-based-confidence, 2026, laya: confidence = 1 - H(p)/log k; noul = max(p,1-p); act_probability (AUROC 0.30).

[13] R. Ghumare, "Laya and jev: System 1 models answer with a type, not text," https://rohitghumare.com/blog/laya-jev-system-1-models/, 2026, mide la fórmula de Jev sobre 30 tickets; una distribución, tres números.

[14] frontier-infra, "jebadiah-9b-v0/v1," https://huggingface.co/frontier-infra/jebadiah-9b-v1, 2026, la temperatura de score aprendida del profesor empeora la calibración en rúbricas humanas.

[15] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 70. PMLR, 2017, pp. 1321–1330. [Online]. Available: https://proceedings.mlr.press/v70/guo17a.html

[16] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 2005, pp. 625–632.

[17] M. P. Naeini, G. F. Cooper, and M. Hauskrecht, "Obtaining well calibrated probabilities using bayesian binning," in *Proceedings of the 29th AAAI Conference on Artificial Intelligence*, 2015, pp. 2901–2907, origen del ECE.

[18] T. Gneiting and A. E. Raftery, "Strictly proper scoring rules, prediction, and estimation," *Journal of the American Statistical Association*, vol. 102, no. 477, pp. 359–378, 2007.

[19] I. J. Good, "Rational decisions," *Journal of the Royal Statistical Society: Series B*, vol. 14, no. 1, pp. 107–114, 1952, origen de la regla logarítmica (log score).

[20] T. B. Roby, "Belief states and the uses of evidence," *Behavioral Science*, vol. 10, no. 3, pp. 255–270, 1965, origen atribuido de la regla esférica; el «Roby 1964» que repite la literatura es la versión previa, no publicada como artículo.

[21] E. S. Epstein, "A scoring system for probability forecasts of ranked categories," *Journal of Applied Meteorology*, vol. 8, no. 6, pp. 985–987, 1969, origen del RPS.

[22] V. R. Jose, "A characterization for the spherical scoring rule," *Theory and Decision*, vol. 66, no. 3, pp. 263–281, 2009, caracterización axiomática de la regla esférica (en línea 2007, impreso 2009).

[23] W. Jitkrittum, N. Gupta, A. K. Menon, H. Narasimhan, A. S. Rawat, and S. Kumar, "When does confidence-based cascade deferral suffice?" in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
[24] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," *Advances in Large Margin Classifiers*, pp. 61–74, 1999.
[25] B. Zadrozny and C. Elkan, "Transforming classifier scores into accurate multiclass probability estimates," in *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2002, pp. 694–699.
[26] V. Vovk, A. Gammerman, and G. Shafer, *Algorithmic Learning in a Random World*. Springer, 2005.
[27] A. N. Angelopoulos and S. Bates, "A gentle introduction to conformal prediction and distribution-free uncertainty quantification," *arXiv preprint arXiv:2107.07511*, 2021.
[28] Archer Hume, "Jev's architecture unmasked," https://archerhume.com/posts/jevs-architecture-unmasked, 2026, 10.000 llamadas a la API; 7 principios.
[29] N. Pai, "Decoding jev: Architecture, inference, and rlcd," https://navinpai.github.io/decoding-jev/, 2026.
[30] Z. Gao and P. Wang, "OpenJev-RLCD: A Working RLCD Implementation," https://arxiv.org/abs/2609.38850, 2026, identidad de varianza; el término RL es el gradiente de la CE suavizada.
[31] L. Đ. Minh, "What RLCD's RL Term Actually Does," https://github.com/LakoreAI/sev, Sep. 2026, preprint + repositorio LakoreAI/sev; reproducción tensor-for-tensor, 30 corridas, ablación de RLCD.
[32] K. Li, Y. He, and Q. Li, "Beyond Calibration: Do a Typed-Decision Model's Probabilities Obey the Probability Axioms?" https://arxiv.org/abs/2609.33209, 2026, 480 pares de negación; s+n=1 falla en 6.4 %.
[33] Y. Sun, J. Xu, J. Shi, and Z. Yang, "Type-Safe Is Not Error-Free: Typed Decision Models Follow the Option Name, Not the Definition Bound to It," https://arxiv.org/abs/2609.26758, 2026, flip de 70.4 pp; AUC 93.8 % ->23.2 %.
[34] G. Ling, M. Xue, and Z. Ye, "Jev in the Wild: A Data-Driven Analysis of the Jev Model's Functionality, Applications and Ecosystem," https://arxiv.org/abs/2609.30216, 2026, 2.170 proyectos de GitHub al 22-sep-2026; cartografía del ecosistema.
[35] G. Nandakishore, "Laya as a Typed Probabilistic Assessor: An Independent Reproduction and a Preregistered Study of Calibration and Selective Escalation," https://arxiv.org/abs/2609.33843, 2026, checkpoint tal cual: sub-confianza 0.214; T=0.469 ->0.037; el umbral no transfiere fuera de muestra (0.0916 ->0.1399).
[36] G. W. Brier, "Verification of forecasts expressed in terms of probability," *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950.